

Analiza zbioru danych mieszkania

Wielowymiarowa analiza danych

Przemysław Peplinski, Wiktor Galewski, Mikołaj Zalewski

2026-01-18

Spis treści

| | |
|---|-----------|
| 1 Wstęp | 2 |
| 1.1 Autorzy | 2 |
| 1.2 Motywacja i cele | 2 |
| 1.3 Opis projektu | 2 |
| 2 Opis danych | 2 |
| 3 Czyszczenie danych | 3 |
| 3.1 Walidacja | 3 |
| 3.2 Obsługa braków wartości | 4 |
| 3.3 Obsługa obserwacji odstających | 4 |
| 4 Analiza eksploracyjna | 4 |
| 4.1 Statystyki opisowe | 4 |
| 4.2 Analiza rozkładów | 5 |
| 4.3 Analiza korelacji | 8 |
| 4.4 Analiza braków danych | 9 |
| 4.5 Analiza obserwacji odstających | 10 |
| 5 Obróbka zmiennych | 11 |
| 5.1 Kodowanie zmiennych kategorycznych | 11 |
| 5.2 Normalizacja zmiennych numerycznych | 11 |

| | | |
|----------|---|-----------|
| 6 | 2 metody | 11 |
| 6.1 | Analiza głównych składowych (PCA) | 11 |
| 6.2 | Analiza korespondencji (CA) | 13 |
| 7 | Wizualizacja metod | 13 |
| 7.1 | Wizualizacje PCA | 13 |
| 7.2 | Wizualizacje CA | 13 |
| 8 | Wnioski | 13 |

1 Wstęp

1.1 Autorzy

Autorami są... Wkład w projekt prezentował się następująco...

1.2 Motywacja i cele

Coś tam...

1.3 Opis projektu

Coś tam...

2 Opis danych

Dane pochodzą... /Dane zostały zebrane...

```
## Rows: 106,169
## Columns: 19
## $ Link <chr> "https://domy.pl/mieszkanie/gdansk-siedlce-malczews~
## $ `Data dodania` <dttm> 2021-02-02 10:24:00, 2021-02-02 11:08:14, 2021-02-~
## $ `Data modyfikacji` <dttm> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
## $ Tytuł <chr> "Trzypokojowe mieszkanie na sprzedaż:", "Gdańsk, Si~
## $ Opis <chr> "Młyny Gdańskie Gdańsk, ul. Malczewskiego Młyny Gda~
## $ Cena <dbl> NA, NA,~
## $ Powierzchnia <dbl> 60.02, 89.63, 60.49, 64.89, 104.66, 72.04, 75.21, 6~
## $ `Cena za metr` <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA,~
```

```

## $ `Liczba pokoi` <dbl> 3, 4, 3, 3, 4, 4, 3, 3, 3, 4, 3, 1, 2, 3, 3, 3, ~
## $ Piętro <dbl> 4, 1, 0, 0, 1, 3, 1, 2, 3, 3, 2, 1, 3, 0, 1, 3, 4, ~
## $ `Liczba pięter` <dbl> NA, ~
## $ `Rok budowy` <dbl> 2023, 2023, 2023, 2023, 2023, 2023, 2023, 202~
## $ Ocena <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
## $ Dzielnica <chr> "Siedlce", "Siedlce", "Siedlce", "Siedlce", "Siedlc~
## $ `Rodzaj budynku` <chr> "Apartamentowiec", "Pozostałe", "Pozostałe", "Pozos~
## $ Rynek <chr> "Pierwotny", "Pierwotny", "Pierwotny", "Pierwotny", ~
## $ Ogłoszeniodawca <chr> "Agencja", "Agencja", "Agencja", "Agencja", "Agencj~
## $ Portal <chr> "Domy", "Morizon", "Morizon", "Morizon", "Morizon", ~
## $ `Numer telefonu` <chr> NA, "585055401", "585055401", "585055401", "5850554~
```

Opisać zmienne...

Wśród zmiennych niepotrzebnych do analizy można wymienić link, tytuł, opis oraz numer telefonu. Zmienne te zostaną zatem usunięte.

3 Czyszczenie danych

3.1 Walidacja

Tak

```

## Rows: 106,169
## Columns: 19
## $ Link <chr> "https://domy.pl/mieszkanie/gdansk-siedlce-malczews~
## $ `Data dodania` <dttm> 2021-02-02 10:24:00, 2021-02-02 11:08:14, 2021-02-~
## $ `Data modyfikacji` <dttm> NA, ~
## $ Tytuł <chr> "Trzypokojowe mieszkanie na sprzedaż:", "Gdańsk, Si~
## $ Opis <chr> "Młynы Gdańskie Gdańsk, ul. Malczewskiego Młyny Gda~
## $ Cena <dbl> NA, ~
## $ Powierzchnia <dbl> 60.02, 89.63, 60.49, 64.89, 104.66, 72.04, 75.21, 6~
## $ `Cena za metr` <dbl> NA, ~
## $ `Liczba pokoi` <dbl> 3, 4, 3, 3, 4, 4, 3, 3, 3, 4, 3, 1, 2, 3, 3, ~
## $ Piętro <dbl> 4, 1, 0, 0, 1, 3, 1, 2, 3, 3, 2, 1, 3, 0, 1, 3, 4, ~
## $ `Liczba pięter` <dbl> NA, ~
## $ `Rok budowy` <dbl> 2023, 2023, 2023, 2023, 2023, 2023, 202~
## $ Ocena <dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
## $ Dzielnica <chr> "Siedlce", "Siedlce", "Siedlce", "Siedlce", "Siedlc~
## $ `Rodzaj budynku` <chr> "Apartamentowiec", "Pozostałe", "Pozostałe", "Pozos~
## $ Rynek <chr> "Pierwotny", "Pierwotny", "Pierwotny", "Pierwotny", ~
## $ Ogłoszeniodawca <chr> "Agencja", "Agencja", "Agencja", "Agencja", "Agencj~
## $ Portal <chr> "Domy", "Morizon", "Morizon", "Morizon", "Morizon", ~
## $ `Numer telefonu` <chr> NA, "585055401", "585055401", "585055401", "5850554~
```

3.2 Obsługa braków wartości

Kilka zmiennych do usunięcia, dla niektórych trzeba usunąć obserwacje, w innych imputować wg obliczeń.

```
## missForest iteration 1 in progress...done!
##   estimated error(s): 1.379711e-05 0.03532471
##   difference(s): 9.168541e-11 0.03261746
##   time: 29.01 seconds
##
## missForest iteration 2 in progress...done!
##   estimated error(s): 1.235244e-05 0.03504698
##   difference(s): 5.99119e-13 0.004266807
##   time: 28.19 seconds
##
## missForest iteration 3 in progress...done!
##   estimated error(s): 1.242352e-05 0.03537198
##   difference(s): 2.322088e-13 0.004550982
##   time: 28.44 seconds
##
## missForest iteration 4 in progress...done!
##   estimated error(s): 1.233419e-05 0.0350588
##   difference(s): 2.511408e-13 0.004973066
##   time: 29.28 seconds
```

3.3 Obsługa obserwacji odstających

Jako tako zostawiamy

4 Analiza eksploracyjna

4.1 Statystyki opisowe

```
## Data dodania  Data modyfikacji    Cena          Powierzchnia
## Min.   :18666   Min.   :0.0000   Min.   : 33000   Min.   : 14.00
## 1st Qu.:19733   1st Qu.:0.0000   1st Qu.: 526925  1st Qu.: 40.00
## Median :20058   Median :0.0000   Median : 669000  Median : 50.60
## Mean   :19980   Mean   :0.3913   Mean   : 794244  Mean   : 54.38
## 3rd Qu.:20249   3rd Qu.:1.0000   3rd Qu.: 899000  3rd Qu.: 64.60
## Max.   :20437   Max.   :1.0000   Max.   :13000000  Max.   :553.00
##
## Cena za metr      Liczba pokoi       Piętro        Rok budowy
```

```

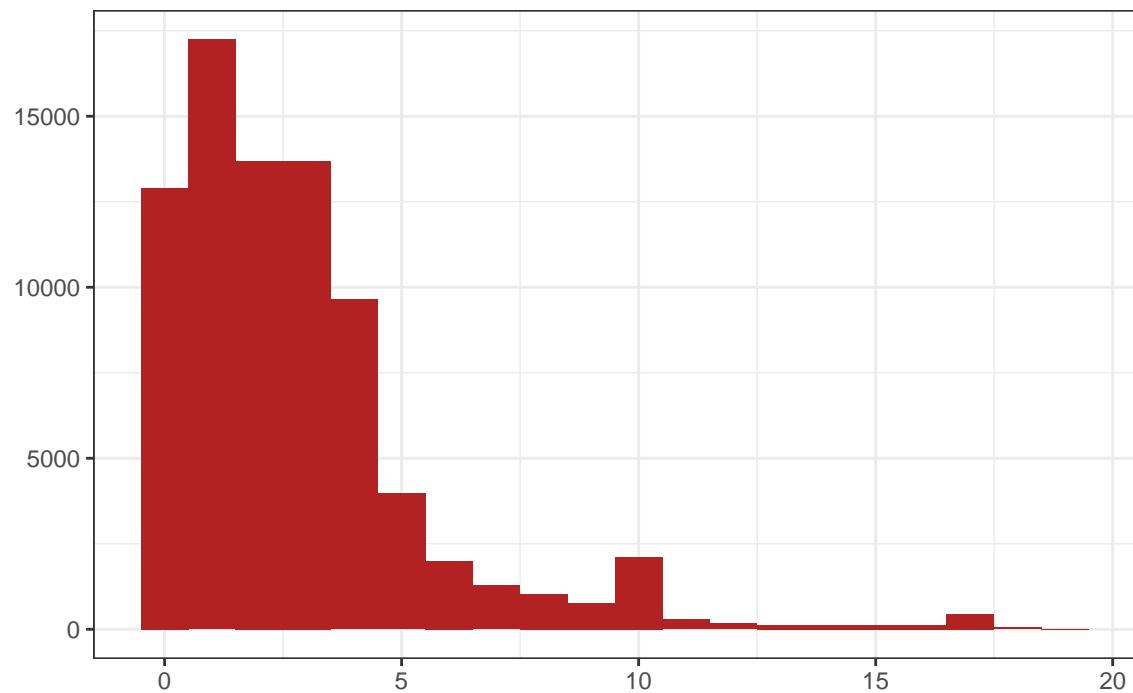
## Min.    : 1121   Min.    : 1.000   Min.    : 0.000   Min.    :1780
## 1st Qu.:11200  1st Qu.: 2.000   1st Qu.: 1.000   1st Qu.:1986
## Median  :13414  Median  : 2.000   Median  : 2.000   Median  :2020
## Mean    :14664   Mean    : 2.535   Mean    : 2.786   Mean    :2004
## 3rd Qu.:16667  3rd Qu.: 3.000   3rd Qu.: 4.000   3rd Qu.:2024
## Max.    :62298   Max.    :24.000   Max.    :19.000   Max.    :2028
##
##                                     Dzielnica          Rodzaj budynku      Rynek
## Śródmieście        :11064   Apartamentowiec:24873   Min.    :0.0000
## Ujeścisko-Łostowice:10920   Blok           :47654     1st Qu.:0.0000
## Jasień             : 9296   Kamienica       : 7236    Median  :0.0000
## Wrzeszcz            : 5576                Mean    :0.3485
## Przymorze           : 5052                3rd Qu.:1.0000
## Siedlce             : 4915                Max.    :1.0000
## (Other)              :32940
## Ogłoszeniodawca          Portal
## Min.    :0.0000   Otodom           :25920
## 1st Qu.:1.0000   Trojmiasto       :16197
## Median  :1.0000   Okolica          : 7993
## Mean    :0.8734   Nieruchomosci-online: 7119
## 3rd Qu.:1.0000   Allegro          : 6505
## Max.    :1.0000   Adresowo         : 3257
## (Other)            :12772

```

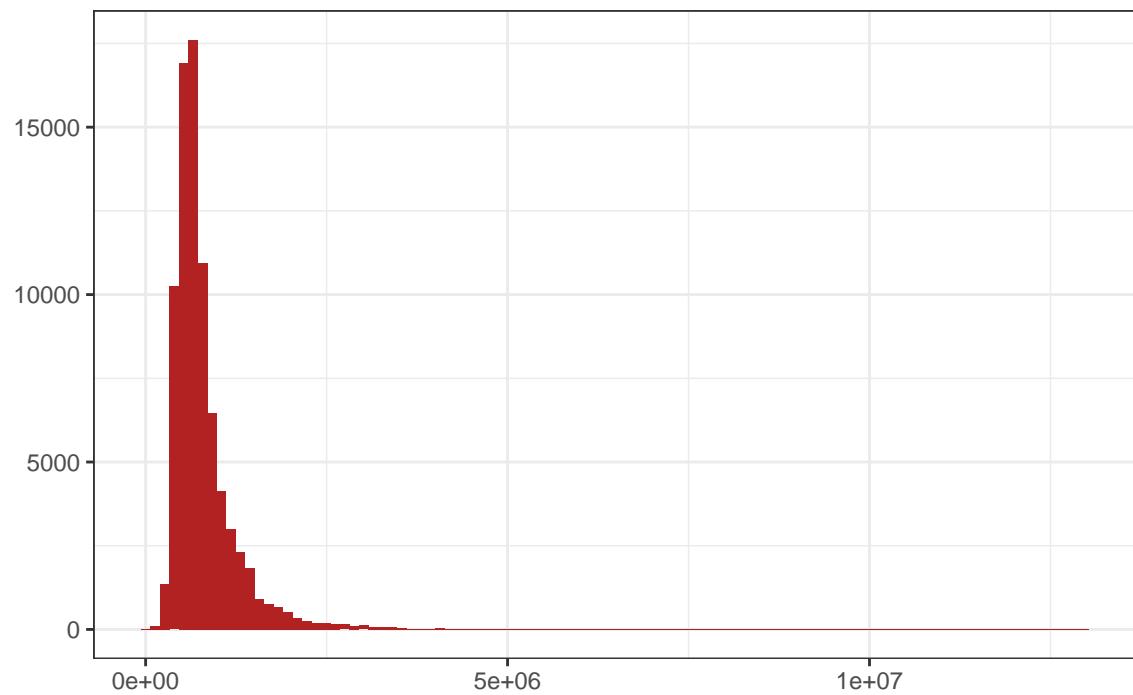
4.2 Analiza rozkładów

Histogramy zmiennych numerycznych, wykresy kolumnowe zmiennych kategorycznych

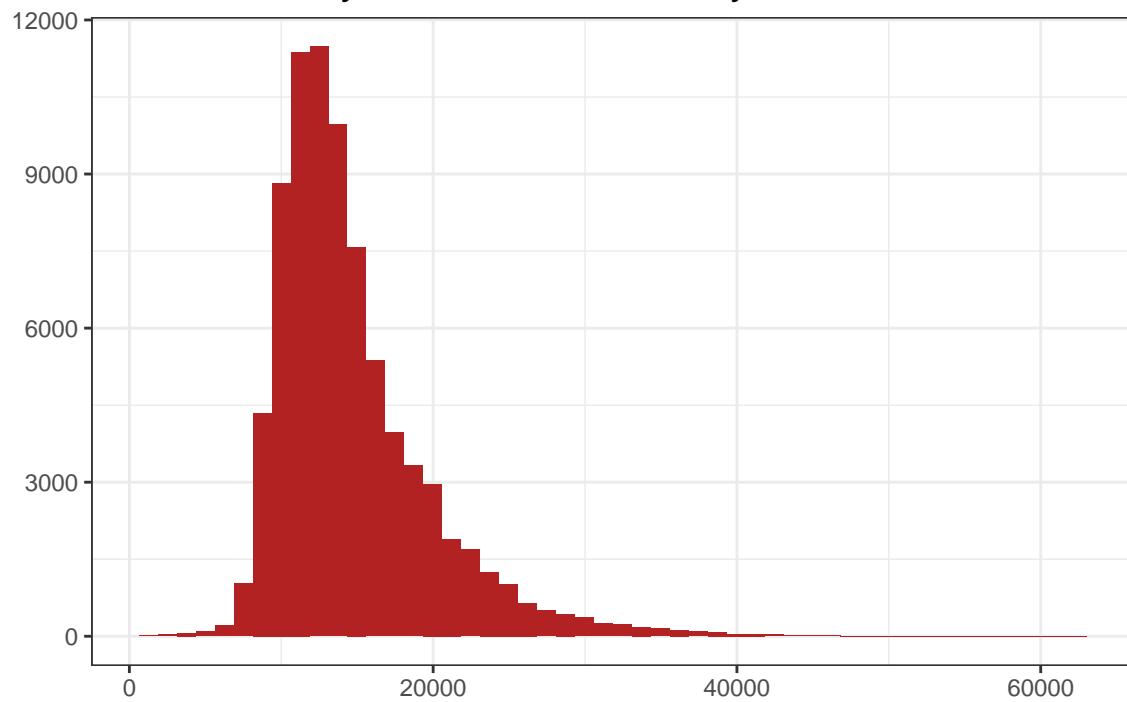
Rozkład pieter mieszkań



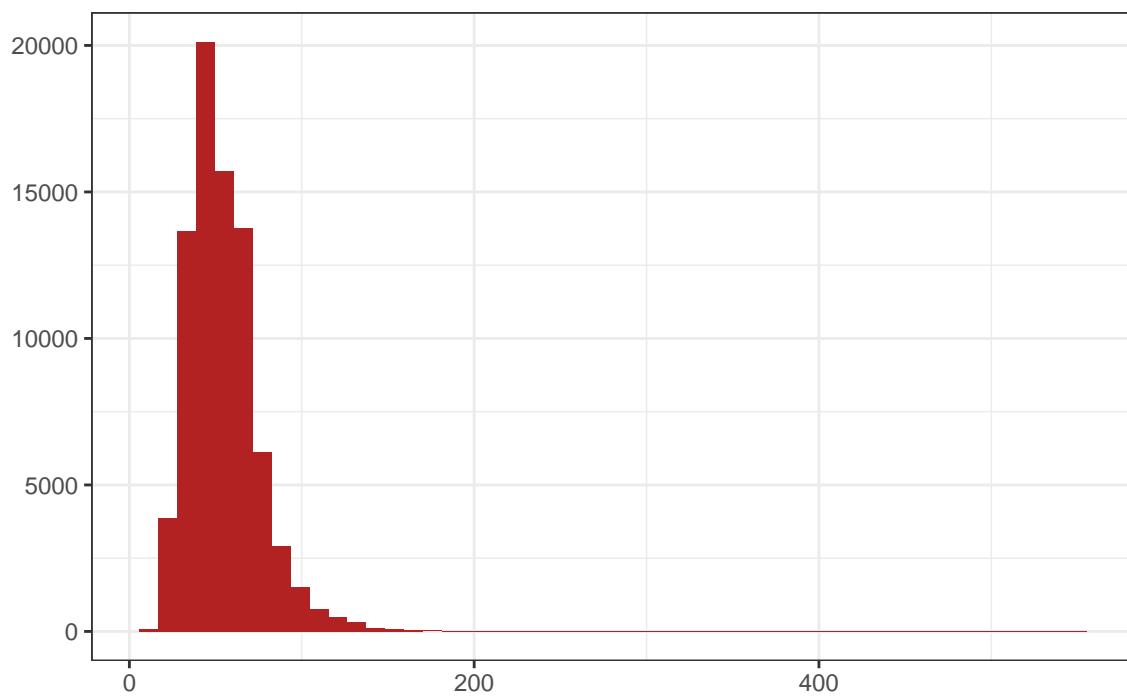
Rozkład cen mieszkań w zł



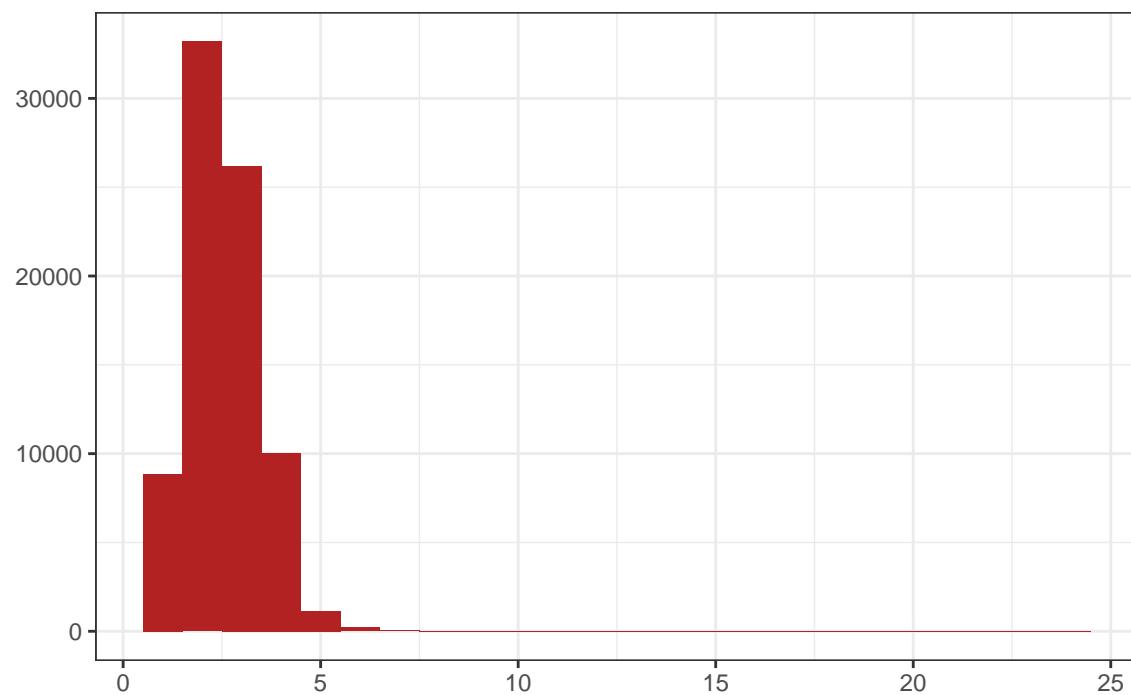
Rozkład ceny za metr kwadratowy mieszkań w zł/m²



Rozkład powierzchni mieszkań w m²

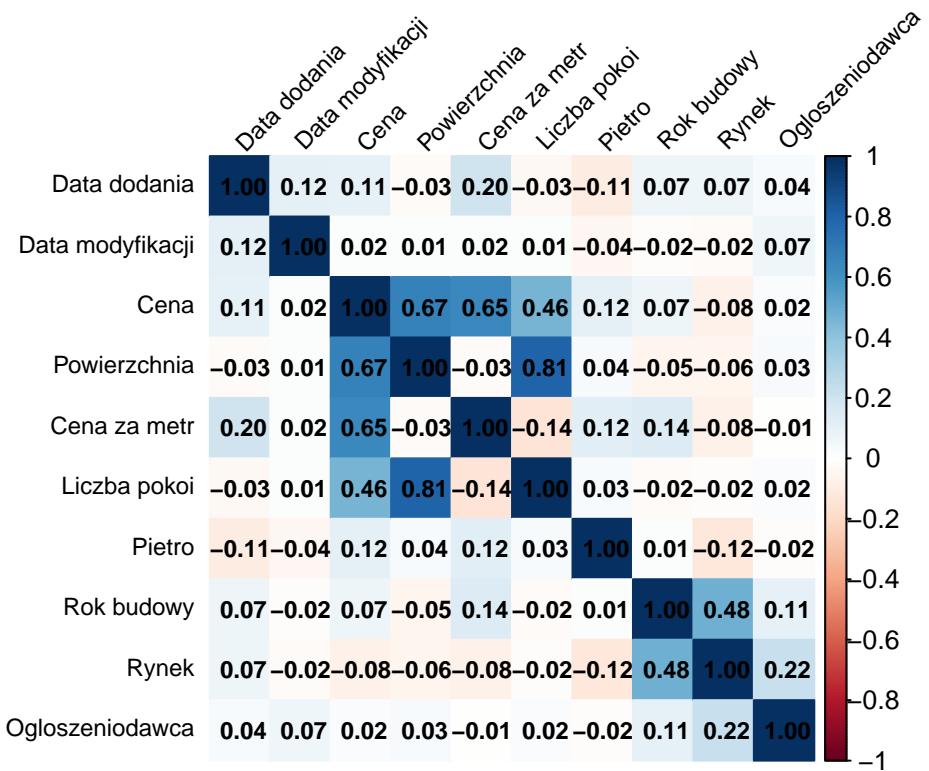


Rozkład liczby pokoi



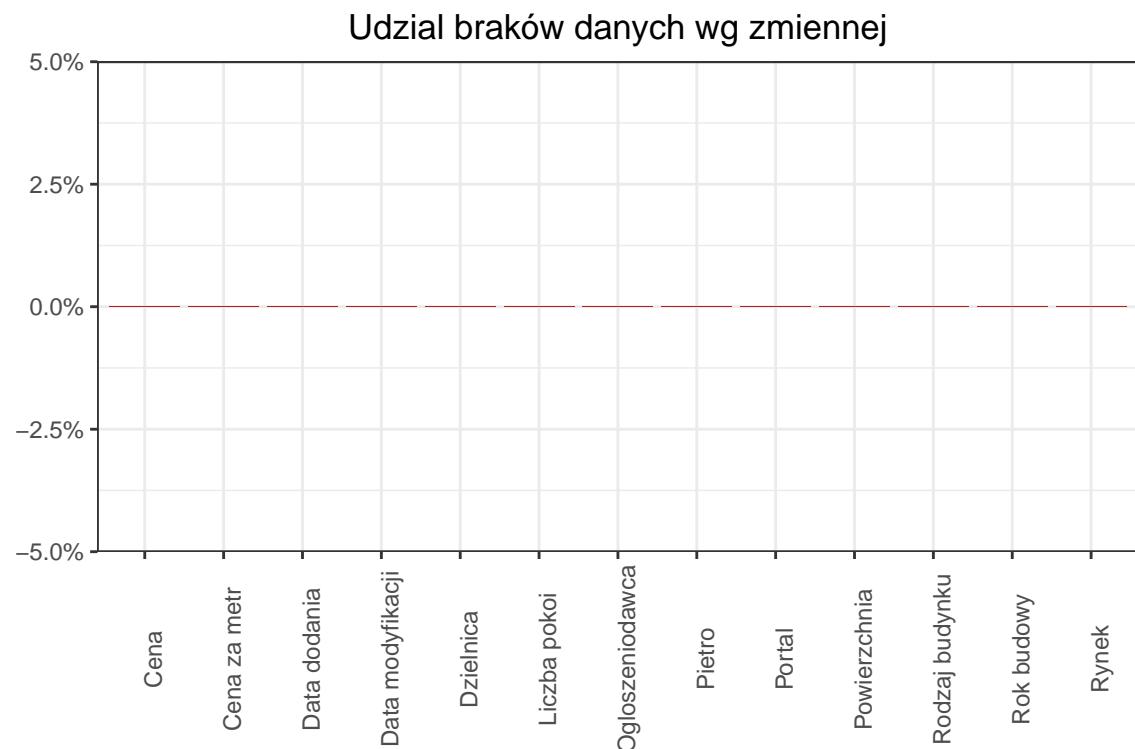
4.3 Analiza korelacji

Macierz korelacji



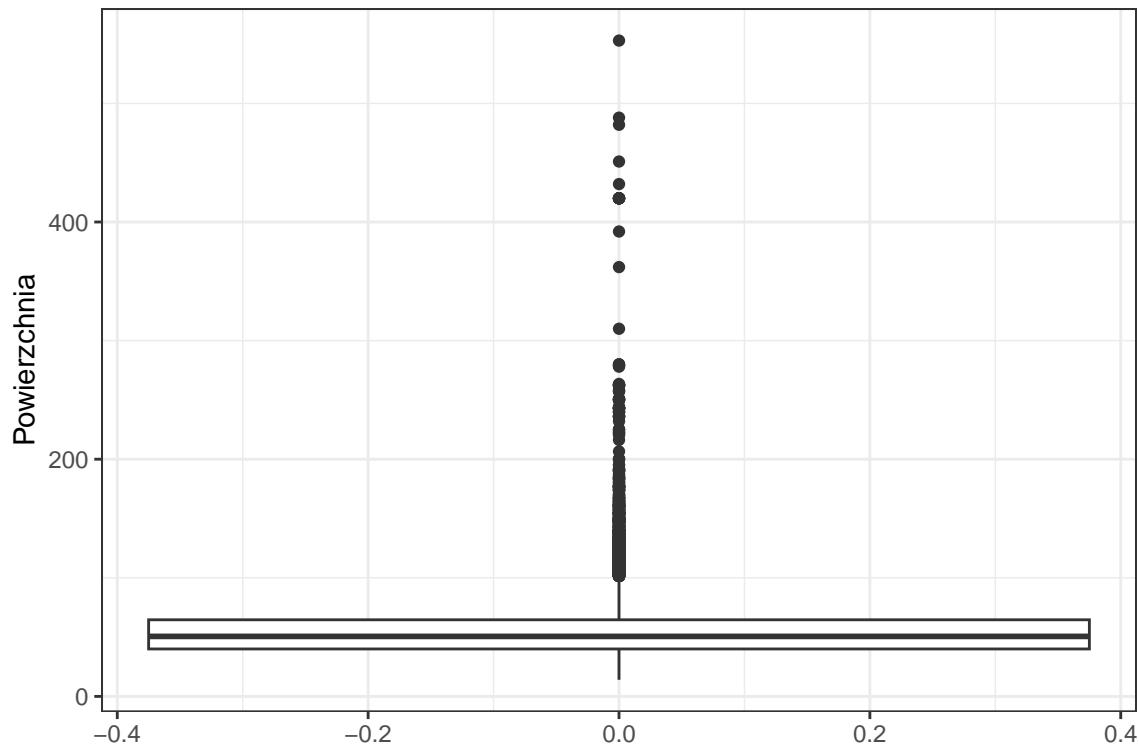
4.4 Analiza braków danych

Krótkie podsumowanie braków danych (wykres słupkowy?)



4.5 Analiza obserwacji odstających

Zrobić boxploty



5 Obróbka zmiennych

5.1 Kodowanie zmiennych kategorycznych

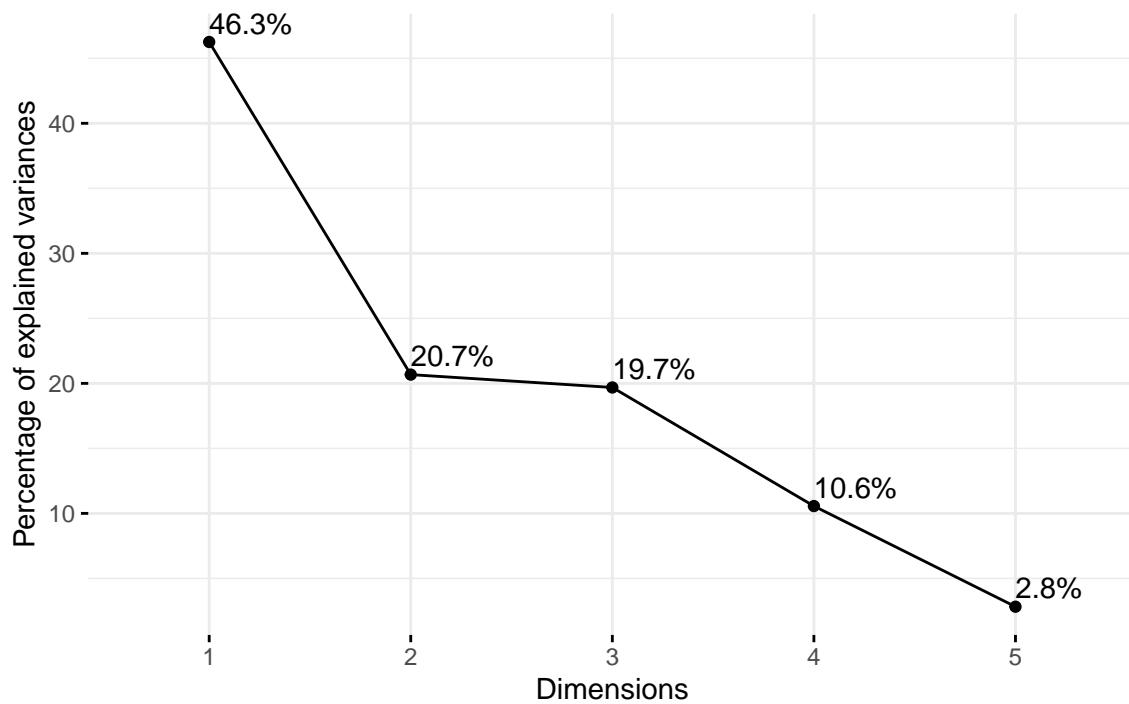
5.2 Normalizacja zmiennych numerycznych

6 2 metody

6.1 Analiza głównych składowych (PCA)

```
## $chisq
## [1] 167.9269
##
## $p.value
## [1] 7.451025e-31
##
## $df
## [1] 10
```

Scree plot



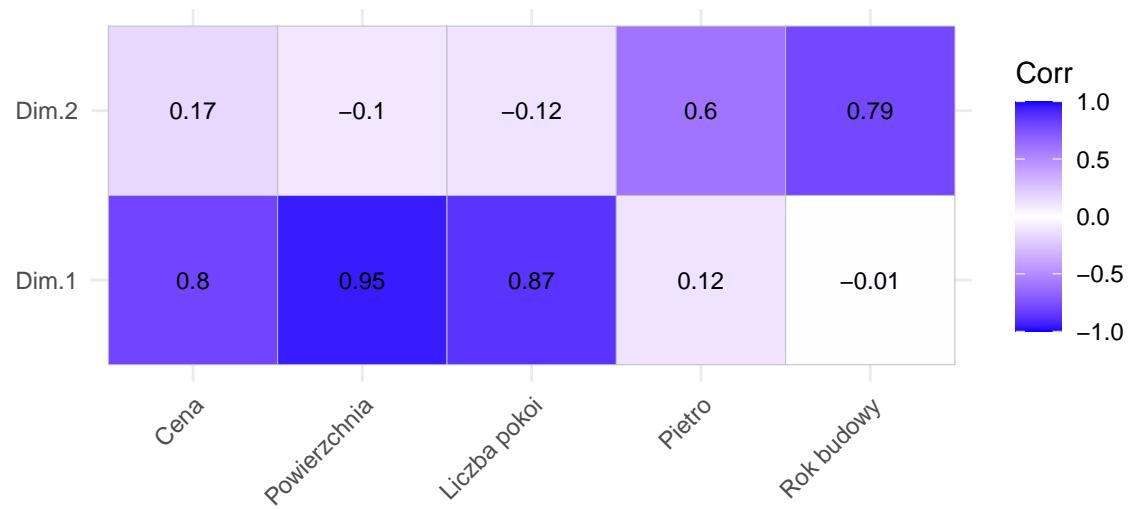
```
##          eigenvalue variance.percent cumulative.variance.percent
## Dim.1    2.3127535      46.255070                46.25507
## Dim.2    1.0336234      20.672469                66.92754
## Dim.3    0.9842327      19.684654                86.61219
## Dim.4    0.5281741      10.563482                97.17567
## Dim.5    0.1412163      2.824326                100.00000
```

Korzystając z kryterium Keisera można określić, że mieszkania można określić za pomocą dwóch zmiennych, ponieważ dla nich wartości własne są większe od 1. Taki sam wniosek można wyciągnąć na podstawie oceny wykresu osypiska, gdyż po drugim wymiarze zmiana wariancji jest znacznie mniejsza.

6.2 Analiza korespondencji (CA)

7 Wizualizacja metod

7.1 Wizualizacje PCA



7.2 Wizualizacje CA

8 Wnioski